

OCR测评标准文档

一、测评目的

- 量化评估不同开源 OCR 引擎在短视频内嵌硬字幕提取场景下的识别精度、场景鲁棒性。
- 对比 AI 生成视频与实拍非 AI 视频两类典型场景下各 OCR 的表现差异。
- 建立统一的短视频字幕 OCR 测评基准与流程，规范输入输出格式与指标计算规则，保障测评结果可对比。

二、测试集与输入规范

2.1 测试集构成

总样本量为 25 条短视频，分为**AI 生成视频**与**非 AI 视频**两类，覆盖主流短视频场景与字幕样式。

(1) AI 生成视频（10 条）



(2) 非 AI 视频（15 条）



2.2 输入统一规则

为保证测评公平性，所有参评 OCR 输入严格遵循以下规范：

- 格式统一**：所有视频统一为 H.264 编码的 MP4 文件，抽帧间隔固定为0.5秒。
- 预处理禁用**：不得提前对视频进行去模糊、对比度增强、超分辨率等画质优化操作，保持原始画质输入。
- 检测范围**：默认开启全画面文字检测。

三、Ground Truth 构建规范

Ground Truth是经人工标注校验的字幕标准答案集，是所有 OCR 效果指标计算的唯一基准。

只考虑关键信息提取，将标点符号替换为空格。

格式示例如下：

代码块

```
1 ocr_gt = ['加班这么晚赶回家', '买点零食搞劳自己', '小心', '没想到就交代在这了', '系统激活中...', '系统激活中... 灵魂跃迁启动...', '坐标锁定 上古大荒山海界', '我没死', '这', '这是哪', '原主记忆装载中', '弟弟把家里的粮食都偷了', '混蛋', '这个世界是大荒年', '原来这具身体的原主', '偷了家里口粮换酒', '结果醉死在了路上', '糟了']
```

四、测评指标体系

以人工标注的字幕真值文本为基准计算，所有指标统一按「单个汉字 / 英文字母 / 数字 = 1 个字符」统计。

- **字符错误率（CER）**：核心量化指标，数值越低精度越高
$$CER = \frac{S + D + I}{N}$$
其中：S = 替换字符数，D = 删除字符数，I = 插入字符数，N = 真值总字符数
- **精确率（Precision）**：识别结果中正确字符的占比，衡量误识别、多字的严重程度
- **召回率（Recall）**：真值字符中被正确识别的占比，衡量漏识别、缺字的严重程度
- **F1 值**：精确率与召回率的调和均值，综合衡量识别整体效果

五、参考数据集


本任务与传统文档 OCR 不同，更接近 video text spotting 场景：模型需要在连续短视频帧中定位、跟踪并识别字幕、贴纸文字、UI 文本和自然场景文字。因此，BOVText 和 DSText V2 是最相近的公开视频文字数据集

优先级	推荐数据集 / 网站入口	为什么像短剧 OCR 场景	用途
1	BOVText	最像短剧/短视频：数据来自 快手 + YouTube ，包含 2000+ 视频、175 万+帧，覆盖 life vlog、cartoon、sports 等开放场景，并区分 caption text / scene text ；支持 detection、recognition、tracking、end-to-end spotting。(GitHub)	最推荐，用来对齐“短视频/短剧里的字幕+画面文字”
2	DSText V2	也是视频文字识别，重点是 dense text / small text / blur / distortion ，适合短剧里小字、角标、水印、复杂背景文字。数据为 140 个 video clips、7 类开放场景，支持 detection、tracking、end-to-end spotting。(Zenodo)	做鲁棒性评测，尤其小字/密集字

3	ICDAR2015 Video Text / RRC 系列	经典视频文字 benchmark，任务就是利用视频时序信息做文字检测和识别；论文里提到 train 25 个视频、test 24 个视频。 publication.imlab.jp)	老牌 baseline，对比方法时可引用
4	RCTW-17 / LSVT / ReCTS / ArT 中文 OCR 数据集合集	短剧 OCR 大概率是中文为主，PaddleOCR 的中文数据集页面汇总了 LSVT、RCTW、ArT 等；其中 RCTW 包含街景、海报、菜单、室内场景和移动应用截图，和短剧里的海报字/聊天截图/UI 字比较接近。 (PaddlePaddle)	中文识别模型预训练/微调
5	TextOCR	面向真实自然图像中的任意形状文字，约 90 万 word annotations；适合补充“画面里非字幕文字”的通用识别能力。 (arXiv)	通用 scene text OCR 预训练
6	COCO-Text / HierText	COCO-Text 是自然图像文字检测识别数据集；HierText 提供 Open Images 上的 word / line / paragraph 层级标注，适合长文本块和复杂排版文字。 vision.cornell.edu)	增强复杂画面文字、段落级文字能力

六、参评开源 OCR 选型

序号	引擎名称	网址	核心优点	缺点
1	PaddleOCR-VL-1.5/1.6 @李润方	https://github.com/PaddlePaddle/PaddleOCR	中文硬字幕识别精度领先，鲁棒性强，生态完善，可搭配自定义后处理达到最优效果；可通过版面分析稳定定位底部字幕区域，适配多行滚动字幕，支持中英文混合字幕	完整依赖包体积大，G复杂；批量抽帧处理滚动的动态字幕帧间一
2	RapidOCR @项昱然	https://github.com/RapidAI/RapidOCR	ONNX格式轻量部署，CPU单帧推理速度快，适合批量抽帧离线提取字幕；模型体积小、资源占用低，可无缝嵌入视频处理流水线；中文基础字幕识别稳定	无字幕场景专项优化，光、立体特效字幕识别支持语义版面分析，易标、水印等干扰文字；适配弱
3	MMOCR @李墨涵	https://github.com/open-mmlab/mmolcr	模块化架构可针对字幕场景定制检测与识别模型，支持自行训练优化特效字幕；检测算法丰富，可适配倾斜、变形的艺术字幕；学术算法更新快，可快速跟进前沿方案	部署与二次开发门槛高无开箱即用的字幕提取装完整流水线；通用预频字幕适配度一般
4	EasyOCR @李墨涵	https://github.com/JaidedAI/EasyOCR	支持80+语种，适合海外多语种短视频字幕提取；API极简，可快速集成到视频抽帧脚本；对倾斜、轻度模糊的字幕有基础识别能力	对中文描边、渐变特效差，复杂画面背景下识别速度偏慢，批量处理长将弹幕、贴纸、水印误
5	DeepSeek-OCR 2	https://github.com/deepseek-ai/DeepSeek-OCR-2	类人阅读顺序还原，能准确还原多行字幕的语序与换行逻辑；对复杂画面、半透明字幕的语义理解能力强，可一定程度过滤非字幕干扰；长文本字幕还原连贯性好	模型参数量大，单帧推合实时字幕提取；对模糊的动态字幕识别精度种字幕支持有限
6	MonkeyOCR	https://github.com/Yuliang-Liu/MonkeyOCR	中英文双语字幕识别精度高，对密集多行字幕还原准确；端到端范式减少检测误差累积，艺术字体字幕适配性优于传统两阶段OCR；推理效率优于同量级大模型OCR	无短视频字幕专项优化边、立体特效字幕适配英双语，不适用多语种工具链薄弱
7	GLM-OCR @项昱然	https://github.com/zai-org/GLM-OCR	0.9B参数量兼顾精度与推理速度，批量抽帧处理效率优于大参数量VLM；对中文复杂背景字幕、水印台标干扰有一定鲁棒性；结构化输出便于直接提取纯字幕文本	两阶段流水线对极端模字幕容错较低；滚动字幕有错乱；卡通体、书法别精度一般
8	dots.ocr	https://github.com/rednote-hilab/dots.ocr	单VLM统一架构，布局检测能力强，可精准区分字幕、弹幕、台标等元素，减少非字幕干扰；多语言覆盖广，小语种字幕识别表现优于多数开源OCR；阅读顺序还原优秀，多行滚动字幕语序准确；支持指定区域定向识别，可固定底部字幕区域提升效率	面向文档场景优化，对变等短视频特效字幕无字体精度下降明显；对滚动的动态字幕适配差在幻觉风险，长字幕可署依赖GPU与vLLM，（离线场景适用性差



参考资料

1. 开源OCR模型对比分析报告【基于多模态大模型】. 知乎专栏, 2025-11-05.
<https://zhuanlan.zhihu.com/p/1969342407054197277>

2. 6款开源中文OCR工具深度评测：性能对比与实战指南. 百度开发者平台, 2025-09-19.
<https://developer.baidu.com/article/detail.html?id=3693214>

3. PaddleOCR-VL-1.6 正式开源：0.9B 轻量架构跑出 96.33% 准确率，2026-06.
<https://www.aitop100.cn/infomation/details/33938>

开源、好复现、并且在 BOVText / DSText V2 / ICDAR2015 Video Text / RRC 系列都很强的模型（后两个更偏工程补位）

优先级	模型	推荐原因	覆盖数据集 / 结果亮点	测试人
1	GoMatchin g++ 润方 李润方	最推荐主 baseline；代码、配置、权重都比较完整；训练参数少，适合短剧 OCR 改造	官方 repo 报告：ICDAR15-video MOTA 72.20 / IDF1 80.11，DSText MOTA 23.23 / IDF1 46.24，BOVText MOTA 52.9 / IDF1 62.8。 repo 也给了 ICDAR15、DSText、BOVText 的训练配置。(GitHub)	

2	GoMatching	GoMatching++ 的原始版本，适合做 ablation / 对照	官方结果：ICDAR15-video MOTA 72.04 / IDF1 80.11，DSText MOTA 22.83 / IDF1 46.06；方法思路是冻结 image text spotter，再训练轻量视频 tracker。(GitHub)	
3	VimTS @李墨涵	新一些的统一 video/image text spotter，适合做跨域泛化；对短剧这种 domain shift 场景有参考价值	官方称在 ICDAR2015-video 和 DSText V2 上，使用 image-level 数据也能超过此前端到端视频文字方法，平均提升约 5.5 MOTA；repo 提供代码、环境和权重。(GitHub)	
4	CoText	实时端到端 Video Text Spotting，适合做“速度/效果”对照	ICDAR2015-video 上 CoText-832 报告 MOTA 59.0 / MOTP 74.5 / IDF1 72.0 / 41 FPS；代码开源，但识别部分有一定限制说明。(GitHub)	
5	TransDETR	Transformer 系经典端到端视频文字模型；覆盖 ICDAR15-video 和 DSText	ICDAR2015-video spotting: TransDETR MOTA 58.4 / IDF1 70.4，增强版 MOTA 60.9 / IDF1 72.8；repo 标明支持 DSText 和中文识别更新，但识别代码释放存在限制。(GitHub)	
6	TransVTSpotter	BOVText 官方早期 ranking 中的重要 baseline；适合引用和横向对比	BOVText 官方表里，TransVTSpotter tracking 达到 MOTA 68.2 / IDF1 64.7；其官方 repo 也报告 ICDAR2015-video tracking MOTA 45.75 / IDF1 57.56。(GitHub)	
7	DeepSolo / DeepSolo+	不是视频 tracker，但很适合作为单帧 OCR / text spotting backbone；GoMatching 系列就是基于 DeepSolo 的 image text spotter	GoMatching 论文明确把 DeepSolo 作为 frozen image text spotter 来转成视频 specialist；DeepSolo 官方 repo 开源，适合做“逐帧检测识别 + tracking”的工程基线。(arXiv)	
8	DavarOCR-YORO	经典视频文字 spotting baseline，代码在 DavarOCR 体系里；不是 SOTA，但可复现、适合做轻量传统方案	DavarOCR 开源 OCR 工具箱包含 Video Text Spotting: YORO；YORO 的核心思路是“You Only Recognize Once”，通过 tracking + quality scoring 减少重复识别，适合视频 OCR 的工程思想参考。(GitHub)	